

Вычислительная математика.
Итерационные методы решения систем
линейных уравнений.

МФТИ

Недостатки прямых методов

Недостатки прямых методов

- Сложность $O(n^3)$ для матриц общего вида

Недостатки прямых методов

- Сложность $O(n^3)$ для матриц общего вида
- Нужны элементы матрицы в явном виде

Недостатки прямых методов

- Сложность $O(n^3)$ для матриц общего вида
- Нужны элементы матрицы в явном виде

$$F : \mathbb{R}^n \rightarrow \mathbb{R}^n; \quad J = \frac{\partial F}{\partial x} = \left[\frac{\partial F_i}{\partial x_j}(x_0) \right]$$

Недостатки прямых методов

- Сложность $O(n^3)$ для матриц общего вида
- Нужны элементы матрицы в явном виде

$$F : \mathbb{R}^n \rightarrow \mathbb{R}^n; \quad J = \frac{\partial F}{\partial x} = \left[\frac{\partial F_i}{\partial x_j}(x_0) \right]$$

$$J(x_0)\Delta x = F(x_0 + \Delta x) - F(x_0) + O(\Delta x^2)$$

Недостатки прямых методов

- Сложность $O(n^3)$ для матриц общего вида
- Нужны элементы матрицы в явном виде

$$F : \mathbb{R}^n \rightarrow \mathbb{R}^n; \quad J = \frac{\partial F}{\partial x} = \left[\frac{\partial F_i}{\partial x_j}(x_0) \right]$$

$$J(x_0)\Delta x = F(x_0 + \Delta x) - F(x_0) + O(\Delta x^2)$$

- Нельзя найти приближение к решению с заданной погрешностью

Недостатки прямых методов

- Сложность $O(n^3)$ для матриц общего вида
- Нужны элементы матрицы в явном виде

$$F : \mathbb{R}^n \rightarrow \mathbb{R}^n; \quad J = \frac{\partial F}{\partial x} = \left[\frac{\partial F_i}{\partial x_j}(x_0) \right]$$

$$J(x_0)\Delta x = F(x_0 + \Delta x) - F(x_0) + O(\Delta x^2)$$

- Нельзя найти приближение к решению с заданной погрешностью
- Сложно использовать специальную структуру матрицы

Недостатки прямых методов

- Сложность $O(n^3)$ для матриц общего вида
- Нужны элементы матрицы в явном виде

$$F : \mathbb{R}^n \rightarrow \mathbb{R}^n; J = \frac{\partial F}{\partial x} = \left[\frac{\partial F_i}{\partial x_j}(x_0) \right]$$

$$J(x_0)\Delta x = F(x_0 + \Delta x) - F(x_0) + O(\Delta x^2)$$

- Нельзя найти приближение к решению с заданной погрешностью
- Сложно использовать специальную структуру матрицы
Пример: если A - разреженная, матрицы L и U , Q и R не будут в общем случае разреженными

Потеря разреженности (демо)

Общий вид простого метода

- Метод простой итерации (МПИ) основан на сведении системы к эквивалентному виду:

Общий вид простого метода

- Метод простой итерации (МПИ) основан на сведении системы к эквивалентному виду:

$$Ax = b \iff x = Sx + f$$

Общий вид простого метода

- Метод простой итерации (МПИ) основан на сведении системы к эквивалентному виду:

$$\begin{aligned} Ax = b &\iff x = Sx + f \\ x^k &= Sx^{k-1} + f \end{aligned}$$

Общий вид простого метода

- Метод простой итерации (МПИ) основан на сведении системы к эквивалентному виду:

$$Ax = b \iff x = Sx + f$$

$$x^k = Sx^{k-1} + f$$

$$e^k = (x^k - x) = S(x^{k-1} - x) =$$

Общий вид простого метода

- Метод простой итерации (МПИ) основан на сведении системы к эквивалентному виду:

$$Ax = b \iff x = Sx + f$$

$$x^k = Sx^{k-1} + f$$

$$\begin{aligned} e^k = (x^k - x) &= S(x^{k-1} - x) = \\ &= S^k(x^0 - x) = S^k e^0 \end{aligned}$$

Общий вид простого метода

- Метод простой итерации (МПИ) основан на сведении системы к эквивалентному виду:

$$Ax = b \iff x = Sx + f$$

$$x^k = Sx^{k-1} + f$$

$$\begin{aligned} e^k = (x^k - x) &= S(x^{k-1} - x) = \\ &= S^k(x^0 - x) = S^k e^0 \end{aligned}$$

- Критерий сходимости:

$$e^k \rightarrow 0 \iff S^k e^0 \rightarrow 0 \forall e^0 \iff \rho(S) < 1$$

Общий вид простого метода

- Метод простой итерации (МПИ) основан на сведении системы к эквивалентному виду:

$$Ax = b \iff x = Sx + f$$

$$x^k = Sx^{k-1} + f$$

$$\begin{aligned} e^k &= (x^k - x) = S(x^{k-1} - x) = \\ &= S^k(x^0 - x) = S^k e^0 \end{aligned}$$

- Критерий сходимости:

$$e^k \rightarrow 0 \iff S^k e^0 \rightarrow 0 \forall e^0 \iff \rho(S) < 1$$

- Достаточное условие сходимости: $\|S\| = q < 1$

$$\|e^k\| = \|S^k e^0\| \leq \|S\|^k \|e^0\| = q^k \|e^0\|$$

Общий вид простого метода

- Метод простой итерации (МПИ) основан на сведении системы к эквивалентному виду:

$$Ax = b \iff x = Sx + f$$

$$x^k = Sx^{k-1} + f$$

$$\begin{aligned} e^k = (x^k - x) &= S(x^{k-1} - x) = \\ &= S^k(x^0 - x) = S^k e^0 \end{aligned}$$

- Критерий сходимости:

$$e^k \rightarrow 0 \iff S^k e^0 \rightarrow 0 \forall e^0 \iff \rho(S) < 1$$

- Достаточное условие сходимости: $\|S\| = q < 1$

$$\|e^k\| = \|S^k e^0\| \leq \|S\|^k \|e^0\| = q^k \|e^0\|$$

- Нужно задать начальное приближение x^0 и критерий остановки, например: $\|Ax^k - b\| \leq \epsilon$

Общий вид с предобуславливателем

- Любой МПИ можно записать в виде:

$$P(x^{k+1} - x^k) = b - Ax^k, \quad k = 0, 1, \dots, \quad P - \text{невырожденная}$$

- $x^{k+1} = (I - P^{-1}A)x^k + P^{-1}b, \quad S = (I - P^{-1}A)$
- Требования к P :
 - 1 $P \approx A^{-1}$
 - 2 Решение системы $Py = g$ стоит $\ll O(n^3)$
- Матрицу P (иногда P^{-1}) называют *предобуславливатель* (preconditioner)

Преимущества итерационных методов

$$x^k = Sx^{k-1} + f$$

Преимущества итерационных методов

$$x^k = Sx^{k-1} + f$$

- Сложность $O(Kn^2)$, где K - число итераций.

Преимущества итерационных методов

$$x^k = Sx^{k-1} + f$$

- Сложность $O(Kn^2)$, где K - число итераций.
- Можно оценить число итераций для заданной точности
$$\|e^k\| \leq q^k \|e^0\| \leq \epsilon \Rightarrow k \geq \frac{\log(\epsilon/\|e^0\|)}{\log q}$$

Преимущества итерационных методов

$$x^k = Sx^{k-1} + f$$

- Сложность $O(Kn^2)$, где K - число итераций.
- Можно оценить число итераций для заданной точности
$$\|e^k\| \leq q^k \|e^0\| \leq \epsilon \Rightarrow k \geq \frac{\log(\epsilon/\|e^0\|)}{\log q}$$
- Нужна только процедура для вычисления произведения Sx

Преимущества итерационных методов

$$x^k = Sx^{k-1} + f$$

- Сложность $O(Kn^2)$, где K - число итераций.
- Можно оценить число итераций для заданной точности
$$\|e^k\| \leq q^k \|e^0\| \leq \epsilon \Rightarrow k \geq \frac{\log(\epsilon/\|e^0\|)}{\log q}$$
- Нужна только процедура для вычисления произведения Sx
- Матрично-векторное умножение легко распараллеливается с высокой эффективностью.

Преимущества итерационных методов


$$x^k = Sx^{k-1} + f$$

- Сложность $O(Kn^2)$, где K - число итераций.
- Можно оценить число итераций для заданной точности
$$\|e^k\| \leq q^k \|e^0\| \leq \epsilon \Rightarrow k \geq \frac{\log(\epsilon/\|e^0\|)}{\log q}$$
- Нужна только процедура для вычисления произведения Sx
- Матрично-векторное умножение легко распараллеливается с высокой эффективностью.
- Для разреженных матриц сложность $O(K \times NNZ(S))$

Развитие итерационных методов

Speed-Up
Factor


Derived from Computational Methods



Развитие итерационных методов

Speed-Up
Factor

Derived from Computational Methods



Список 10 важнейших алгоритмов 20-го века, *Computing in Science and Engineering*, 2001 год:

- итерационные методы подпространств Крылова

Метод Рундсона

Метод Рундсона

- Рассмотрим систему $Ax = b$, $A = A^T > 0$:

Метод Рундсона

- Рассмотрим систему $Ax = b$, $A = A^T > 0$:

$$Ax = b$$

Метод Ричардсона

- Рассмотрим систему $Ax = b$, $A = A^T > 0$:

$$Ax = b$$

$$\tau(Ax - b) = 0$$

Метод Ричардсона

- Рассмотрим систему $Ax = b$, $A = A^T > 0$:

$$Ax = b$$

$$\tau(Ax - b) = 0$$

$$x - \tau(Ax - b) = x$$

Метод Ричардсона

- Рассмотрим систему $Ax = b$, $A = A^T > 0$:

$$Ax = b$$

$$\tau(Ax - b) = 0$$

$$x - \tau(Ax - b) = x$$

$$\underline{x^{k+1} = x^k - \tau(Ax^k - b) = (I - \tau A)x^k + \tau b}$$

Метод Рундсона

- Рассмотрим систему $Ax = b$, $A = A^T > 0$:

$$Ax = b$$

$$\tau(Ax - b) = 0$$

$$x - \tau(Ax - b) = x$$

$$\underline{x^{k+1} = x^k - \tau(Ax^k - b) = (I - \tau A)x^k + \tau b}$$

τ - итерационный параметр. $S = I - \tau A$

Метод Рундсона

- Рассмотрим систему $Ax = b$, $A = A^T > 0$:

$$Ax = b$$

$$\tau(Ax - b) = 0$$

$$x - \tau(Ax - b) = x$$

$$\underline{x^{k+1} = x^k - \tau(Ax^k - b) = (I - \tau A)x^k + \tau b}$$

τ - итерационный параметр. $S = I - \tau A$

- Критерий сходимости:

Метод Рундсону

- Рассмотрим систему $Ax = b$, $A = A^T > 0$:

$$Ax = b$$

$$\tau(Ax - b) = 0$$

$$x - \tau(Ax - b) = x$$

$$\underline{x^{k+1} = x^k - \tau(Ax^k - b) = (I - \tau A)x^k + \tau b}$$

τ - итерационный параметр. $S = I - \tau A$

- Критерий сходимости:

$$\text{sp}(I - \tau A) = 1 - \tau \text{sp}(A), \lambda_i(A) > 0$$

Метод Рундсону

- Рассмотрим систему $Ax = b$, $A = A^T > 0$:

$$Ax = b$$

$$\tau(Ax - b) = 0$$

$$x - \tau(Ax - b) = x$$

$$\underline{x^{k+1} = x^k - \tau(Ax^k - b) = (I - \tau A)x^k + \tau b}$$

τ - итерационный параметр. $S = I - \tau A$

- Критерий сходимости:

$$\text{sp}(I - \tau A) = 1 - \tau \text{sp}(A), \lambda_i(A) > 0$$

$$|1 - \tau \lambda_i| < 1, i = 1, \dots, n \Rightarrow$$

Метод Рундсона

- Рассмотрим систему $Ax = b$, $A = A^T > 0$:

$$Ax = b$$

$$\tau(Ax - b) = 0$$

$$x - \tau(Ax - b) = x$$

$$\underline{x^{k+1} = x^k - \tau(Ax^k - b) = (I - \tau A)x^k + \tau b}$$

τ - итерационный параметр. $S = I - \tau A$

- Критерий сходимости:

$$\text{sp}(I - \tau A) = 1 - \tau \text{sp}(A), \lambda_i(A) > 0$$

$$|1 - \tau \lambda_i| < 1, i = 1, \dots, n \Rightarrow$$

$$(1 - \tau \lambda_i)^2 < 1 \Rightarrow \tau \lambda_i(\tau \lambda_i - 2) < 0 \Rightarrow 0 < \tau < \underline{\underline{\frac{2}{\lambda_{\max}}}}$$

Оптимальный параметр

Оптимальный параметр

- $\|e^k\|_2 = \|(I - \tau A)^k e^0\|_2 \leq \|(I - \tau A)\|_2^k \|e^0\|_2$

Оптимальный параметр

- $\|e^k\|_2 = \|(I - \tau A)^k e^0\|_2 \leq \|(I - \tau A)\|_2^k \|e^0\|_2$
- $\|(I - \tau A)\|_2 = \max_{\lambda \in sp(A)} |1 - \tau \lambda|$

Оптимальный параметр

- $\|e^k\|_2 = \|(I - \tau A)^k e^0\|_2 \leq \|(I - \tau A)\|_2^k \|e^0\|_2$
- $\|(I - \tau A)\|_2 = \max_{\lambda \in sp(A)} |1 - \tau \lambda|$
- Часто, известны только оценки границы спектра:

$$sp(A) \in [m, M]$$


Оптимальный параметр

- $\|e^k\|_2 = \|(I - \tau A)^k e^0\|_2 \leq \|(I - \tau A)\|_2^k \|e^0\|_2$
- $\|(I - \tau A)\|_2 = \max_{\lambda \in sp(A)} |1 - \tau \lambda|$
- Часто, известны только оценки границы спектра:


$$sp(A) \in [m, M]$$

- $\tau^* = \arg \min_{\tau} \max_{\lambda \in [m, M]} |1 - \tau \lambda|$

Оптимальный параметр




Оптимальный параметр



Оптимальное значение:

$$1 - \tau m = \tau M - 1 \Rightarrow \tau^* = \frac{2}{M + m} \Rightarrow$$

Оптимальный параметр




Оптимальное значение:

$$1 - \tau m = \tau M - 1 \Rightarrow \tau^* = \frac{2}{M + m} \Rightarrow$$

$$\|(I - \tau^* A)\|_2 = q^* = \frac{M - m}{M + m} =$$

Оптимальный параметр




Оптимальное значение:

$$1 - \tau m = \tau M - 1 \Rightarrow \tau^* = \frac{2}{M + m} \Rightarrow$$

$$\|(I - \tau^* A)\|_2 = q^* = \frac{M - m}{M + m} = \frac{M/m - 1}{M/m + 1} =$$

Оптимальный параметр




Оптимальное значение:

$$1 - \tau m = \tau M - 1 \Rightarrow \tau^* = \frac{2}{M + m} \Rightarrow$$

$$\|(I - \tau^* A)\|_2 = q^* = \frac{M - m}{M + m} = \frac{M/m - 1}{M/m + 1} = \frac{\text{cond}_2(A) - 1}{\text{cond}_2(A) + 1}$$

Оптимальный параметр



Оптимальное значение:

$$1 - \tau m = \tau M - 1 \Rightarrow \tau^* = \frac{2}{M + m} \Rightarrow$$

$$\|(I - \tau^* A)\|_2 = q^* = \frac{M - m}{M + m} = \frac{M/m - 1}{M/m + 1} = \frac{\text{cond}_2(A) - 1}{\text{cond}_2(A) + 1}$$

Скорость сходимости зависит от обусловленности!

Методы Якоби и Гаусса-Зейделя

Методы Якоби и Гаусса-Зейделя

- Общая идея: $A = M - N$, M - обратимая и легко обращается (система решается за $\ll O(n^3)$):

Методы Якоби и Гаусса-Зейделя

- Общая идея: $A = M - N$, M - обратимая и легко обращается (система решается за $\ll O(n^3)$):
$$Mx = Nx + b \Rightarrow Mx^{k+1} = Nx^k + b,$$

Методы Якоби и Гаусса-Зейделя

- Общая идея: $A = M - N$, M - обратимая и легко обращается (система решается за $\ll O(n^3)$):
$$Mx = Nx + b \Rightarrow Mx^{k+1} = Nx^k + b, x^{k+1} = M^{-1}(Nx^k + b)$$

Методы Якоби и Гаусса-Зейделя

- Общая идея: $A = M - N$, M - обратимая и легко обращается (система решается за $\ll O(n^3)$):
$$Mx = Nx + b \Rightarrow Mx^{k+1} = Nx^k + b, x^{k+1} = M^{-1}(Nx^k + b)$$
- Легко обращаются:
 - ▶ Диагональные матрицы – $O(n)$
 - ▶ Треугольные матрицы – $O(n^2)$

Методы Якоби и Гаусса-Зейделя

- Общая идея: $A = M - N$, M - обратимая и легко обращается (система решается за $\ll O(n^3)$):
$$Mx = Nx + b \Rightarrow Mx^{k+1} = Nx^k + b, x^{k+1} = M^{-1}(Nx^k + b)$$
- Легко обращаются:
 - ▶ Диагональные матрицы – $O(n)$
 - ▶ Треугольные матрицы – $O(n^2)$
- $A = L + D + U$,
 L - строго нижнетреугольная часть
 D - диагональная часть
 U - строго верхнетреугольная часть.

Методы Якоби и Гаусса-Зейделя

- Общая идея: $A = M - N$, M - обратимая и легко обращается (система решается за $\ll O(n^3)$):
$$Mx = Nx + b \Rightarrow Mx^{k+1} = Nx^k + b, x^{k+1} = M^{-1}(Nx^k + b)$$
- Легко обращаются:
 - ▶ Диагональные матрицы – $O(n)$
 - ▶ Треугольные матрицы – $O(n^2)$
- $A = L + D + U$,
 L - строго нижнетреугольная часть
 D - диагональная часть
 U - строго верхнетреугольная часть.
- Предполагается, что D - невырожденная.

Методы Якоби и Гаусса-Зейделя

- Общая идея: $A = M - N$, M - обратимая и *легко обращается* (система решается за $\ll O(n^3)$):
$$Mx = Nx + b \Rightarrow Mx^{k+1} = Nx^k + b, x^{k+1} = M^{-1}(Nx^k + b)$$
- Легко обращаются:
 - ▶ Диагональные матрицы – $O(n)$
 - ▶ Треугольные матрицы – $O(n^2)$
- $A = L + D + U$,
 L - строго нижнетреугольная часть
 D - диагональная часть
 U - строго верхнетреугольная часть.
- Предполагается, что D - невырожденная.
- Метод Якоби:
$$Dx^{k+1} = -(L + U)x^k + b$$

Методы Якоби и Гаусса-Зейделя

- Общая идея: $A = M - N$, M - обратимая и *легко обращается* (система решается за $\ll O(n^3)$):
$$Mx = Nx + b \Rightarrow Mx^{k+1} = Nx^k + b, x^{k+1} = M^{-1}(Nx^k + b)$$
- Легко обращаются:
 - ▶ Диагональные матрицы – $O(n)$
 - ▶ Треугольные матрицы – $O(n^2)$
- $A = L + D + U$,
 L - строго нижнетреугольная часть
 D - диагональная часть
 U - строго верхнетреугольная часть.
- Предполагается, что D - невырожденная.
- Метод Якоби: $Dx^{k+1} = -(L + U)x^k + b$
- Метод Зейделя: $(L + D)x^{k+1} = -Ux^k + b$

Метод Якоби

$$x^{k+1} = -D^{-1}(L + U)x^k + D^{-1}b$$

Метод Якоби

$$x^{k+1} = -D^{-1}(L + U)x^k + D^{-1}b$$

Теорема 7.1 Достаточное условие сходимости метода Якоби

Если матрица A имеет строчное диагональное преобладание, то метод Якоби сходится.

Метод Якоби

$$x^{k+1} = -D^{-1}(L + U)x^k + D^{-1}b$$

Теорема 7.1 Достаточное условие сходимости метода Якоби

Если матрица A имеет строчное диагональное преобладание, то метод Якоби сходится.

- докажем, что $\|D^{-1}(L + U)\|_{\infty} < 1$

Метод Якоби

$$x^{k+1} = -D^{-1}(L + U)x^k + D^{-1}b$$

Теорема 7.1 Достаточное условие сходимости метода Якоби

Если матрица A имеет строчное диагональное преобладание, то метод Якоби сходится.

- докажем, что $\|D^{-1}(L + U)\|_{\infty} < 1$
- $|a_{ii}| > \sum_{j \neq i} |a_{ij}|$, $i = 1, \dots, n$ (определение диагонального преобладания) \Rightarrow

Метод Якоби

$$x^{k+1} = -D^{-1}(L + U)x^k + D^{-1}b$$

Теорема 7.1 Достаточное условие сходимости метода Якоби

Если матрица A имеет строчное диагональное преобладание, то метод Якоби сходится.

- докажем, что $\|D^{-1}(L + U)\|_{\infty} < 1$
- $|a_{ii}| > \sum_{j \neq i} |a_{ij}|$, $i = 1, \dots, n$ (определение диагонального преобладания) \Rightarrow
- $\|D^{-1}(L + U)\|_{\infty} = \max_i \sum_{j \neq i} \left| \frac{a_{ij}}{a_{ii}} \right| = \max_i \frac{\sum_{j \neq i} |a_{ij}|}{|a_{ii}|} < 1 \square$

Метод Якоби

$$x^{k+1} = -D^{-1}(L + U)x^k + D^{-1}b$$

Теорема 7.2 Необходимое и достаточное условие сходимости метода Якоби

Для сходимости метода Якоби необходимо и достаточно, чтобы все корни уравнения

$$\begin{vmatrix} \lambda a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & \lambda a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & \lambda a_{nn} \end{vmatrix} = 0$$

по модулю не превосходили единицы ($|\lambda| \leq 1$).

Алгоритм метода Якоби

```
A
b
xkp1[:] = 0 # начальное приближение
```

```
xk[:] = 0
```

```
while (||dot(A, xkp1) - b|| > tol)
```

```
    xk = xkp1
```

```
    for i = 1, n
```

```
        xkp1[i] = b[i]
```

```
        for j = 1, n; j != i
```

```
            xkp1[i] = xkp1[i] - A[i,j] * xk[j]
```

```
        xkp1[i] = xkp1[i] / A[i,i]
```

Алгоритм метода Якоби

```
A
b
xkp1[:] = 0 # начальное приближение
xk[:] = 0
while (||dot(A, xkp1) - b|| > tol)
    xk = xkp1
    for i = 1, n
        xkp1[i] = b[i]
        for j = 1, n; j != i
            xkp1[i] = xkp1[i] - A[i,j] * xk[j]
        xkp1[i] = xkp1[i] / A[i,i]
```

- Метод Якоби редко используется в чистом виде

Алгоритм метода Якоби

```
A
b
xkp1[:] = 0 # начальное приближение
xk[:] = 0
while (||dot(A, xkp1) - b|| > tol)
    xk = xkp1
    for i = 1, n
        xkp1[i] = b[i]
        for j = 1, n; j != i
            xkp1[i] = xkp1[i] - A[i,j] * xk[j]
        xkp1[i] = xkp1[i] / A[i,i]
```

- Метод Якоби редко используется в чистом виде
- Acceleration of the Jacobi iterative method by factors exceeding 100 using scheduled relaxation, JCP, 2014

Пример программы для метода Якоби

Метод Зейделя

$$x^{k+1} = -(L + D)^{-1}Ux^k + (L + D)^{-1}b$$

Метод Зейделя

$$x^{k+1} = -(L + D)^{-1}Ux^k + (L + D)^{-1}b$$

Теорема 7.3 Достаточное условие сходимости метода Зейделя

Если $A \in \mathbb{R}^{n \times n}$, $A = A^T > 0$, то метод Зейделя сходится.

Метод Зейделя

$$x^{k+1} = -(L + D)^{-1}Ux^k + (L + D)^{-1}b$$

Теорема 7.3 Достаточное условие сходимости метода Зейделя

Если $A \in \mathbb{R}^{n \times n}$, $A = A^T > 0$, то метод Зейделя сходится.

- $A = A^T > 0 \Rightarrow A = L + D + L^T$

Метод Зейделя

$$x^{k+1} = -(L + D)^{-1}Ux^k + (L + D)^{-1}b$$

Теорема 7.3 Достаточное условие сходимости метода Зейделя

Если $A \in \mathbb{R}^{n \times n}$, $A = A^T > 0$, то метод Зейделя сходится.

- $A = A^T > 0 \Rightarrow A = L + D + L^T$
- $\langle Ae_k, e_k \rangle = a_{kk} > 0 \Rightarrow D > 0$

Метод Зейделя

$$x^{k+1} = -(L + D)^{-1}Ux^k + (L + D)^{-1}b$$

Теорема 7.3 Достаточное условие сходимости метода Зейделя

Если $A \in \mathbb{R}^{n \times n}$, $A = A^T > 0$, то метод Зейделя сходится.

- $A = A^T > 0 \Rightarrow A = L + D + L^T$
- $\langle Ae_k, e_k \rangle = a_{kk} > 0 \Rightarrow D > 0$
- $x^{k+1} = -(L + D)^{-1}L^T x^k + (L + D)^{-1}b =$
 $\boxed{(I - (L + D)^{-1}A)} x^k + (L + D)^{-1}b$

Метод Зейделя

$$x^{k+1} = -(L + D)^{-1}Ux^k + (L + D)^{-1}b$$

Теорема 7.3 Достаточное условие сходимости метода Зейделя

Если $A \in \mathbb{R}^{n \times n}$, $A = A^T > 0$, то метод Зейделя сходится.

- $A = A^T > 0 \Rightarrow A = L + D + L^T$
- $\langle Ae_k, e_k \rangle = a_{kk} > 0 \Rightarrow D > 0$
- $x^{k+1} = -(L + D)^{-1}L^T x^k + (L + D)^{-1}b =$
 $\boxed{(I - (L + D)^{-1}A)} x^k + (L + D)^{-1}b$
- Можно ввести A -норму: $\|v\|_A^2 \equiv \langle Av, v \rangle = \langle v, v \rangle_A$,
где $\langle \cdot, \cdot \rangle$ - обычное скалярное произведение

Метод Зейделя(2)

$$\|e^{k+1}\|_A^2 \equiv \langle Ae^{k+1}, e^{k+1} \rangle =$$

Метод Зейделя(2)

$$\begin{aligned}\|e^{k+1}\|_A^2 &\equiv \langle Ae^{k+1}, e^{k+1} \rangle = \\ &= \langle A(I - (L + D)^{-1}A)e^k, (I - (L + D)^{-1}A)e^k \rangle =\end{aligned}$$

Метод Зейделя(2)

$$\begin{aligned}\|e^{k+1}\|_A^2 &\equiv \langle Ae^{k+1}, e^{k+1} \rangle = \\ &= \langle A(I - (L + D)^{-1}A)e^k, (I - (L + D)^{-1}A)e^k \rangle = \\ &= \langle Ae^k - A(L + D)^{-1}Ae^k, e^k - (L + D)^{-1}Ae^k \rangle \square\square\end{aligned}$$

Метод Зейделя(2)

$$\begin{aligned}\|e^{k+1}\|_A^2 &\equiv \langle Ae^{k+1}, e^{k+1} \rangle = \\ &= \langle A(I - (L + D)^{-1}A)e^k, (I - (L + D)^{-1}A)e^k \rangle = \\ &= \langle Ae^k - A(L + D)^{-1}Ae^k, e^k - (L + D)^{-1}Ae^k \rangle \boxed{=}\end{aligned}$$

Обозначим $v = (L + D)^{-1}Ae^k$; $Ae^k = (L + D)v$ (1)

Метод Зейделя(2)

$$\begin{aligned}\|e^{k+1}\|_A^2 &\equiv \langle Ae^{k+1}, e^{k+1} \rangle = \\ &= \langle A(I - (L + D)^{-1}A)e^k, (I - (L + D)^{-1}A)e^k \rangle = \\ &= \langle Ae^k - A(L + D)^{-1}Ae^k, e^k - (L + D)^{-1}Ae^k \rangle \boxed{=}\end{aligned}$$

Обозначим $v = (L + D)^{-1}Ae^k$; $Ae^k = (L + D)v$ (1)

$$\boxed{=} \langle Ae^k, e^k \rangle - \langle Av, e^k \rangle - \langle Ae^k, v \rangle + \langle Av, v \rangle =$$

Метод Зейделя(2)

$$\begin{aligned}\|e^{k+1}\|_A^2 &\equiv \langle Ae^{k+1}, e^{k+1} \rangle = \\ &= \langle A(I - (L + D)^{-1}A)e^k, (I - (L + D)^{-1}A)e^k \rangle = \\ &= \langle Ae^k - A(L + D)^{-1}Ae^k, e^k - (L + D)^{-1}Ae^k \rangle \boxed{=}\end{aligned}$$

Обозначим $v = (L + D)^{-1}Ae^k$; $Ae^k = (L + D)v$ (1)

$$\begin{aligned}\boxed{=}\langle Ae^k, e^k \rangle - \langle Av, e^k \rangle - \langle Ae^k, v \rangle + \langle Av, v \rangle = \\ = \|e^k\|_A^2 - \left(2\langle (L + D)v, v \rangle - \langle (L + D + L^T)v, v \rangle \right) =\end{aligned}$$

Метод Зейделя(2)

$$\begin{aligned}\|e^{k+1}\|_A^2 &\equiv \langle Ae^{k+1}, e^{k+1} \rangle = \\ &= \langle A(I - (L + D)^{-1}A)e^k, (I - (L + D)^{-1}A)e^k \rangle = \\ &= \langle Ae^k - A(L + D)^{-1}Ae^k, e^k - (L + D)^{-1}Ae^k \rangle \boxed{=}\end{aligned}$$

Обозначим $v = (L + D)^{-1}Ae^k; Ae^k = (L + D)v$ (1)

$$\begin{aligned}\boxed{=}\langle Ae^k, e^k \rangle - \langle Av, e^k \rangle - \langle Ae^k, v \rangle + \langle Av, v \rangle &= \\ = \|e^k\|_A^2 - \left(2\langle (L + D)v, v \rangle - \langle (L + D + L^T)v, v \rangle \right) &= \\ = \|e^k\|_A^2 - \langle Dv, v \rangle \leq \underline{\|e^k\|_A^2 - d\|v\|_2^2} \text{ (2)}, \quad d = \min_i D_{ii} = \min_i a_{ii}\end{aligned}$$

Метод Зейделя(2)

$$\begin{aligned}\|e^{k+1}\|_A^2 &\equiv \langle Ae^{k+1}, e^{k+1} \rangle = \\ &= \langle A(I - (L + D)^{-1}A)e^k, (I - (L + D)^{-1}A)e^k \rangle = \\ &= \langle Ae^k - A(L + D)^{-1}Ae^k, e^k - (L + D)^{-1}Ae^k \rangle \boxed{=}\end{aligned}$$

Обозначим $v = (L + D)^{-1}Ae^k$; $Ae^k = (L + D)v$ (1)

$$\begin{aligned}\boxed{=}&\langle Ae^k, e^k \rangle - \langle Av, e^k \rangle - \langle Ae^k, v \rangle + \langle Av, v \rangle = \\ &= \|e^k\|_A^2 - \left(2\langle (L + D)v, v \rangle - \langle (L + D + L^T)v, v \rangle \right) = \\ &= \|e^k\|_A^2 - \langle Dv, v \rangle \leq \underline{\|e^k\|_A^2 - d\|v\|_2^2} \text{ (2)}, \quad d = \min_i D_{ii} = \min_i a_{ii} \\ \|e^k\|_A^2 &= \langle Ae^k, e^k \rangle = \langle (L + D)v, A^{-1}(L + D)v \rangle \leq\end{aligned}$$

Метод Зейделя(2)

$$\begin{aligned}\|e^{k+1}\|_A^2 &\equiv \langle Ae^{k+1}, e^{k+1} \rangle = \\ &= \langle A(I - (L + D)^{-1}A)e^k, (I - (L + D)^{-1}A)e^k \rangle = \\ &= \langle Ae^k - A(L + D)^{-1}Ae^k, e^k - (L + D)^{-1}Ae^k \rangle \boxed{=}\end{aligned}$$

Обозначим $v = (L + D)^{-1}Ae^k; Ae^k = (L + D)v$ (1)

$$\begin{aligned}\boxed{=}&\langle Ae^k, e^k \rangle - \langle Av, e^k \rangle - \langle Ae^k, v \rangle + \langle Av, v \rangle = \\ &= \|e^k\|_A^2 - \left(2\langle (L + D)v, v \rangle - \langle (L + D + L^T)v, v \rangle \right) = \\ &= \|e^k\|_A^2 - \langle Dv, v \rangle \leq \underline{\|e^k\|_A^2 - d\|v\|_2^2} \text{ (2)}, \quad d = \min_i D_{ii} = \min_i a_{ii} \\ \|e^k\|_A^2 &= \langle Ae^k, e^k \rangle = \langle (L + D)v, A^{-1}(L + D)v \rangle \leq \\ \|A^{-1}\|_2 \|(L + D)\|_2^2 \|v\|_2^2 &= \lambda_{\min}^{-1} \|(L + D)\|_2^2 \|v\|_2^2 \Rightarrow \text{из (2)} : \end{aligned}$$

Метод Зейделя(2)

$$\begin{aligned}\|e^{k+1}\|_A^2 &\equiv \langle Ae^{k+1}, e^{k+1} \rangle = \\ &= \langle A(I - (L + D)^{-1}A)e^k, (I - (L + D)^{-1}A)e^k \rangle = \\ &= \langle Ae^k - A(L + D)^{-1}Ae^k, e^k - (L + D)^{-1}Ae^k \rangle \equiv\end{aligned}$$

Обозначим $v = (L + D)^{-1}Ae^k; Ae^k = (L + D)v$ (1)

$$\begin{aligned}\equiv &\langle Ae^k, e^k \rangle - \langle Av, e^k \rangle - \langle Ae^k, v \rangle + \langle Av, v \rangle = \\ &= \|e^k\|_A^2 - \left(2\langle (L + D)v, v \rangle - \langle (L + D + L^T)v, v \rangle \right) = \\ &= \|e^k\|_A^2 - \langle Dv, v \rangle \leq \underline{\|e^k\|_A^2 - d\|v\|_2^2} \text{ (2)}, \quad d = \min_i D_{ii} = \min_i a_{ii}\end{aligned}$$

$$\begin{aligned}\|e^k\|_A^2 &= \langle Ae^k, e^k \rangle = \langle (L + D)v, A^{-1}(L + D)v \rangle \leq \\ &\|A^{-1}\|_2 \|(L + D)\|_2^2 \|v\|_2^2 = \lambda_{\min}^{-1} \|(L + D)\|_2^2 \|v\|_2^2 \Rightarrow \text{из (2):}\end{aligned}$$

$$\underline{\|e^{k+1}\|_A^2 \leq (1 - \lambda_{\min} d \|L + D\|_2^{-2}) \|e^k\|_A^2} \quad \square$$

Метод Зейделя

$$x^{k+1} = -(L + D)^{-1}Ux^k + (L + D)^{-1}b$$

Теорема 7.4 Необходимое и достаточное условие сходимости метода Зейделя

Для сходимости метода Зейделя необходимо и достаточно, чтобы все корни уравнения

$$\begin{vmatrix} \lambda a_{11} & a_{12} & \dots & a_{1n} \\ \lambda a_{21} & \lambda a_{22} & \dots & a_{2n} \\ \dots & \dots & \dots & \dots \\ \lambda a_{n1} & \lambda a_{n2} & \dots & \lambda a_{nn} \end{vmatrix} = 0$$

по модулю не превосходили единицы ($|\lambda| \leq 1$).

Алгоритм метода Зейделя

$$(L + D)x^{k+1} = -Ux^k + b$$

```
A
b
xkp1[:] = 0 # начальное приближение
xk[:] = 0
```

```
while (||dot(A, xkp1) - b|| > tol)
    xk = xkp1
    for i = 1, n
        xkp1[i] = b[i]
        for j = 1, i-1
            xkp1[i] = xkp1[i] - A[i,j] * xkp1[j]
        for j = i+1, n # матрица U
            xkp1[i] = xkp1[i] - A[i,j] * xk[j]
        xkp1[i] = xkp1[i] / A[i,i]
```

Квадратичные функционалы и линейные системы

Квадратичные функционалы и линейные системы

- Для $A = A^T \in \mathbb{R}^{n \times n}$ рассмотрим:

$$f(x) = \frac{1}{2} \langle Ax, x \rangle - \langle b, x \rangle = \frac{1}{2} x^T A x - x^T b$$

Квадратичные функционалы и линейные системы

- Для $A = A^T \in \mathbb{R}^{n \times n}$ рассмотрим:

$$f(x) = \frac{1}{2} \langle Ax, x \rangle - \langle b, x \rangle = \frac{1}{2} x^T A x - x^T b$$

- Пусть z - решение системы $Az = b$. Если $A > 0$, то:

$$E(x) \equiv f(x) - f(z) = 0.5 \langle A(x - z), x - z \rangle > 0, \forall x \neq z$$

$\Rightarrow z$ - точка минимума

Квадратичные функционалы и линейные системы

- Для $A = A^T \in \mathbb{R}^{n \times n}$ рассмотрим:

$$f(x) = \frac{1}{2} \langle Ax, x \rangle - \langle b, x \rangle = \frac{1}{2} x^T A x - x^T b$$

- Пусть z - решение системы $Az = b$. Если $A > 0$, то:

$$E(x) \equiv f(x) - f(z) = 0.5 \langle A(x - z), x - z \rangle > 0, \forall x \neq z$$

$\Rightarrow z$ - точка минимума

- Для произвольной A можно ввести *функционал невязки*:

$$R(x) = \|b - Ax\|_2$$

Квадратичные функционалы и линейные системы

- Для $A = A^T \in \mathbb{R}^{n \times n}$ рассмотрим:

$$f(x) = \frac{1}{2} \langle Ax, x \rangle - \langle b, x \rangle = \frac{1}{2} x^T A x - x^T b$$

- Пусть z - решение системы $Az = b$. Если $A > 0$, то:

$$E(x) \equiv f(x) - f(z) = 0.5 \langle A(x - z), x - z \rangle > 0, \forall x \neq z$$

$\Rightarrow z$ - точка минимума

- Для произвольной A можно ввести *функционал невязки*:

$$R(x) = \|b - Ax\|_2$$

- Общая идея: $x^{k+1} = x^k - \tau^k (Ax^k - b) = x^k - \tau^k r^k$

Квадратичные функционалы и линейные системы

- Для $A = A^T \in \mathbb{R}^{n \times n}$ рассмотрим:

$$f(x) = \frac{1}{2} \langle Ax, x \rangle - \langle b, x \rangle = \frac{1}{2} x^T A x - x^T b$$

- Пусть z - решение системы $Az = b$. Если $A > 0$, то:

$$E(x) \equiv f(x) - f(z) = 0.5 \langle A(x - z), x - z \rangle > 0, \forall x \neq z$$

$\Rightarrow z$ - точка минимума

- Для произвольной A можно ввести *функционал невязки*:

$$R(x) = \|b - Ax\|_2$$

- Общая идея: $x^{k+1} = x^k - \tau^k (Ax^k - b) = x^k - \tau^k r^k$
 $\tau^k = \arg \min_{\tau} F(x^k - \tau r^k), \quad F(x) = E(x), R(x)$

Метод наискорейшего спуска

Метод наискорейшего спуска

- $F(x) = E(x) = \frac{1}{2}\langle Ax, x \rangle - \langle b, x \rangle + f(z)$

Метод наискорейшего спуска

- $F(x) = E(x) = \frac{1}{2}\langle Ax, x \rangle - \langle b, x \rangle + f(z)$
- $\nabla E(x^k) = Ax^k - b = r^k$ (градиентный спуск)

Метод наискорейшего спуска

- $F(x) = E(x) = \frac{1}{2}\langle Ax, x \rangle - \langle b, x \rangle + f(z)$
- $\nabla E(x^k) = Ax^k - b = r^k$ (градиентный спуск)
- $x^{k+1} = x^k - \tau^k(Ax^k - b) = x^k - \tau^k \nabla f(x^k)$

Метод наискорейшего спуска

- $F(x) = E(x) = \frac{1}{2}\langle Ax, x \rangle - \langle b, x \rangle + f(x)$
- $\nabla E(x^k) = Ax^k - b = r^k$ (градиентный спуск)
- $x^{k+1} = x^k - \tau^k(Ax^k - b) = x^k - \tau^k \nabla f(x^k)$

$$f(x^{k+1}) = \frac{1}{2}\langle A(x^k - \tau r^k), x^k - \tau r^k \rangle - \langle b, x^k - \tau r^k \rangle =$$

Метод наискорейшего спуска

- $F(x) = E(x) = \frac{1}{2}\langle Ax, x \rangle - \langle b, x \rangle + f(x)$
- $\nabla E(x^k) = Ax^k - b = r^k$ (градиентный спуск)
- $x^{k+1} = x^k - \tau^k(Ax^k - b) = x^k - \tau^k \nabla f(x^k)$

$$\begin{aligned} f(x^{k+1}) &= \frac{1}{2}\langle A(x^k - \tau r^k), x^k - \tau r^k \rangle - \langle b, x^k - \tau r^k \rangle = \\ &= \frac{1}{2}\langle Ax^k, x^k \rangle - \frac{1}{2}\tau \langle Ax^k, r^k \rangle - \frac{1}{2}\tau \langle Ar^k, x^k \rangle + \\ &+ \frac{1}{2}\tau^2 \langle Ar^k, r^k \rangle - \langle b, x^k \rangle + \tau \langle b, r^k \rangle = \end{aligned}$$

Метод наискорейшего спуска

- $F(x) = E(x) = \frac{1}{2}\langle Ax, x \rangle - \langle b, x \rangle + f(z)$
- $\nabla E(x^k) = Ax^k - b = r^k$ (градиентный спуск)
- $x^{k+1} = x^k - \tau^k(Ax^k - b) = x^k - \tau^k \nabla f(x^k)$

$$\begin{aligned} f(x^{k+1}) &= \frac{1}{2}\langle A(x^k - \tau r^k), x^k - \tau r^k \rangle - \langle b, x^k - \tau r^k \rangle = \\ &= \frac{1}{2}\langle Ax^k, x^k \rangle - \frac{1}{2}\tau \langle Ax^k, r^k \rangle - \frac{1}{2}\tau \langle Ar^k, x^k \rangle + \\ &+ \frac{1}{2}\tau^2 \langle Ar^k, r^k \rangle - \langle b, x^k \rangle + \tau \langle b, r^k \rangle = \\ &= \frac{1}{2}\tau^2 \langle Ar^k, r^k \rangle - \tau \langle Ax^k - b, r^k \rangle + \dots = \end{aligned}$$

Метод наискорейшего спуска

- $F(x) = E(x) = \frac{1}{2}\langle Ax, x \rangle - \langle b, x \rangle + f(x)$
- $\nabla E(x^k) = Ax^k - b = r^k$ (градиентный спуск)
- $x^{k+1} = x^k - \tau^k(Ax^k - b) = x^k - \tau^k \nabla f(x^k)$

$$\begin{aligned} f(x^{k+1}) &= \frac{1}{2}\langle A(x^k - \tau r^k), x^k - \tau r^k \rangle - \langle b, x^k - \tau r^k \rangle = \\ &= \frac{1}{2}\langle Ax^k, x^k \rangle - \frac{1}{2}\tau \langle Ax^k, r^k \rangle - \frac{1}{2}\tau \langle Ar^k, x^k \rangle + \\ &+ \frac{1}{2}\tau^2 \langle Ar^k, r^k \rangle - \langle b, x^k \rangle + \tau \langle b, r^k \rangle = \\ &= \frac{1}{2}\tau^2 \langle Ar^k, r^k \rangle - \tau \langle Ax^k - b, r^k \rangle + \dots = \\ &= \frac{1}{2}\tau^2 \langle Ar^k, r^k \rangle - \tau \langle r^k, r^k \rangle + \dots = \Phi(\tau) \end{aligned}$$

Метод наискорейшего спуска

- $F(x) = E(x) = \frac{1}{2}\langle Ax, x \rangle - \langle b, x \rangle + f(z)$
- $\nabla E(x^k) = Ax^k - b = r^k$ (градиентный спуск)
- $x^{k+1} = x^k - \tau^k(Ax^k - b) = x^k - \tau^k \nabla f(x^k)$

$$\begin{aligned} f(x^{k+1}) &= \frac{1}{2}\langle A(x^k - \tau r^k), x^k - \tau r^k \rangle - \langle b, x^k - \tau r^k \rangle = \\ &= \frac{1}{2}\langle Ax^k, x^k \rangle - \frac{1}{2}\tau \langle Ax^k, r^k \rangle - \frac{1}{2}\tau \langle Ar^k, x^k \rangle + \\ &+ \frac{1}{2}\tau^2 \langle Ar^k, r^k \rangle - \langle b, x^k \rangle + \tau \langle b, r^k \rangle = \\ &= \frac{1}{2}\tau^2 \langle Ar^k, r^k \rangle - \tau \langle Ax^k - b, r^k \rangle + \dots = \\ &= \frac{1}{2}\tau^2 \langle Ar^k, r^k \rangle - \tau \langle r^k, r^k \rangle + \dots = \Phi(\tau) \end{aligned}$$

$$\Phi'(\tau) = \tau \langle Ar^k, r^k \rangle - \langle r^k, r^k \rangle = 0 \Rightarrow \tau^k = \frac{\langle r^k, r^k \rangle}{\langle Ar^k, r^k \rangle}$$

- $P(x^{k+1} - x^k) = b - Ax^k$

Предобуславливание

- $P(x^{k+1} - x^k) = b - Ax^k$
- Метод Рундсона: $P = \tau^{-1}I$

Предобуславливание

- $P(x^{k+1} - x^k) = b - Ax^k$
- Метод Рундсона: $P = \tau^{-1}I$
- Метод Якоби: $P = D$

Предобуславливание

- $P(x^{k+1} - x^k) = b - Ax^k$
- Метод Рундсона: $P = \tau^{-1}I$
- Метод Якоби: $P = D$
- Метод Зейделя: $P = (L + D)$

Предобуславливание

- $P(x^{k+1} - x^k) = b - Ax^k$
- Метод Рундсона: $P = \tau^{-1}I$
- Метод Якоби: $P = D$
- Метод Зейделя: $P = (L + D)$
- Можно «комбинировать» предобуславливатели, например, применить метод Рундсона к $D^{-1}Ax = D^{-1}b$

Предобуславливание

- $P(x^{k+1} - x^k) = b - Ax^k$
- Метод Рундсона: $P = \tau^{-1}I$
- Метод Якоби: $P = D$
- Метод Зейделя: $P = (L + D)$
- Можно «комбинировать» предобуславливатели, например, применить метод Рундсона к $D^{-1}Ax = D^{-1}b$
- Простые методы (МПИ) используются в качестве предобуславливателей для более сложных методов

Заключение

- Сравнение прямых и итерационных методов
- Метод Рундсона
- Методы Якоби и Зейделя
- Методы, основанные на минимизации функционала